

“Análise de Viés em Modelo de Inteligência Artificial”

O viés surge porque o algoritmo aprende apenas os padrões presentes no conjunto de dados utilizado no treinamento. Quando as imagens representam apenas grupos específicos de pessoas em cada categoria, o modelo associa características visuais limitadas a determinadas funções ou perfis sociais. Dessa forma, o sistema cria uma interpretação distorcida da realidade e passa a realizar classificações incorretas baseadas em aparência, roupa ou contexto visual.

Essa classificação afeta diretamente o indivíduo que o sistema marginaliza. A pessoa se sente invisibilizada, julgada ou estereotipada por características superficiais. Em ambientes profissionais, esse tipo de erro reforça preconceitos sociais, limita oportunidades e contribui para discriminações em processos de seleção, reconhecimento ou tomada de decisão automatizada.

Uma ação mitigadora envolve a implementação de um processo de “Human-in-the-loop”, no qual pessoas revisam continuamente os dados antes e depois do treinamento do modelo. Uma equipe diversa analisa as imagens utilizadas, identifica padrões discriminatórios e garante maior representatividade no conjunto de dados. Esse acompanhamento humano reduz distorções, aumenta a equidade do sistema e evita que o algoritmo reproduza preconceitos sociais de forma automática.




Figura 1 — Exemplo de classificação enviesada realizada pelo modelo treinado no Teachable Machine.